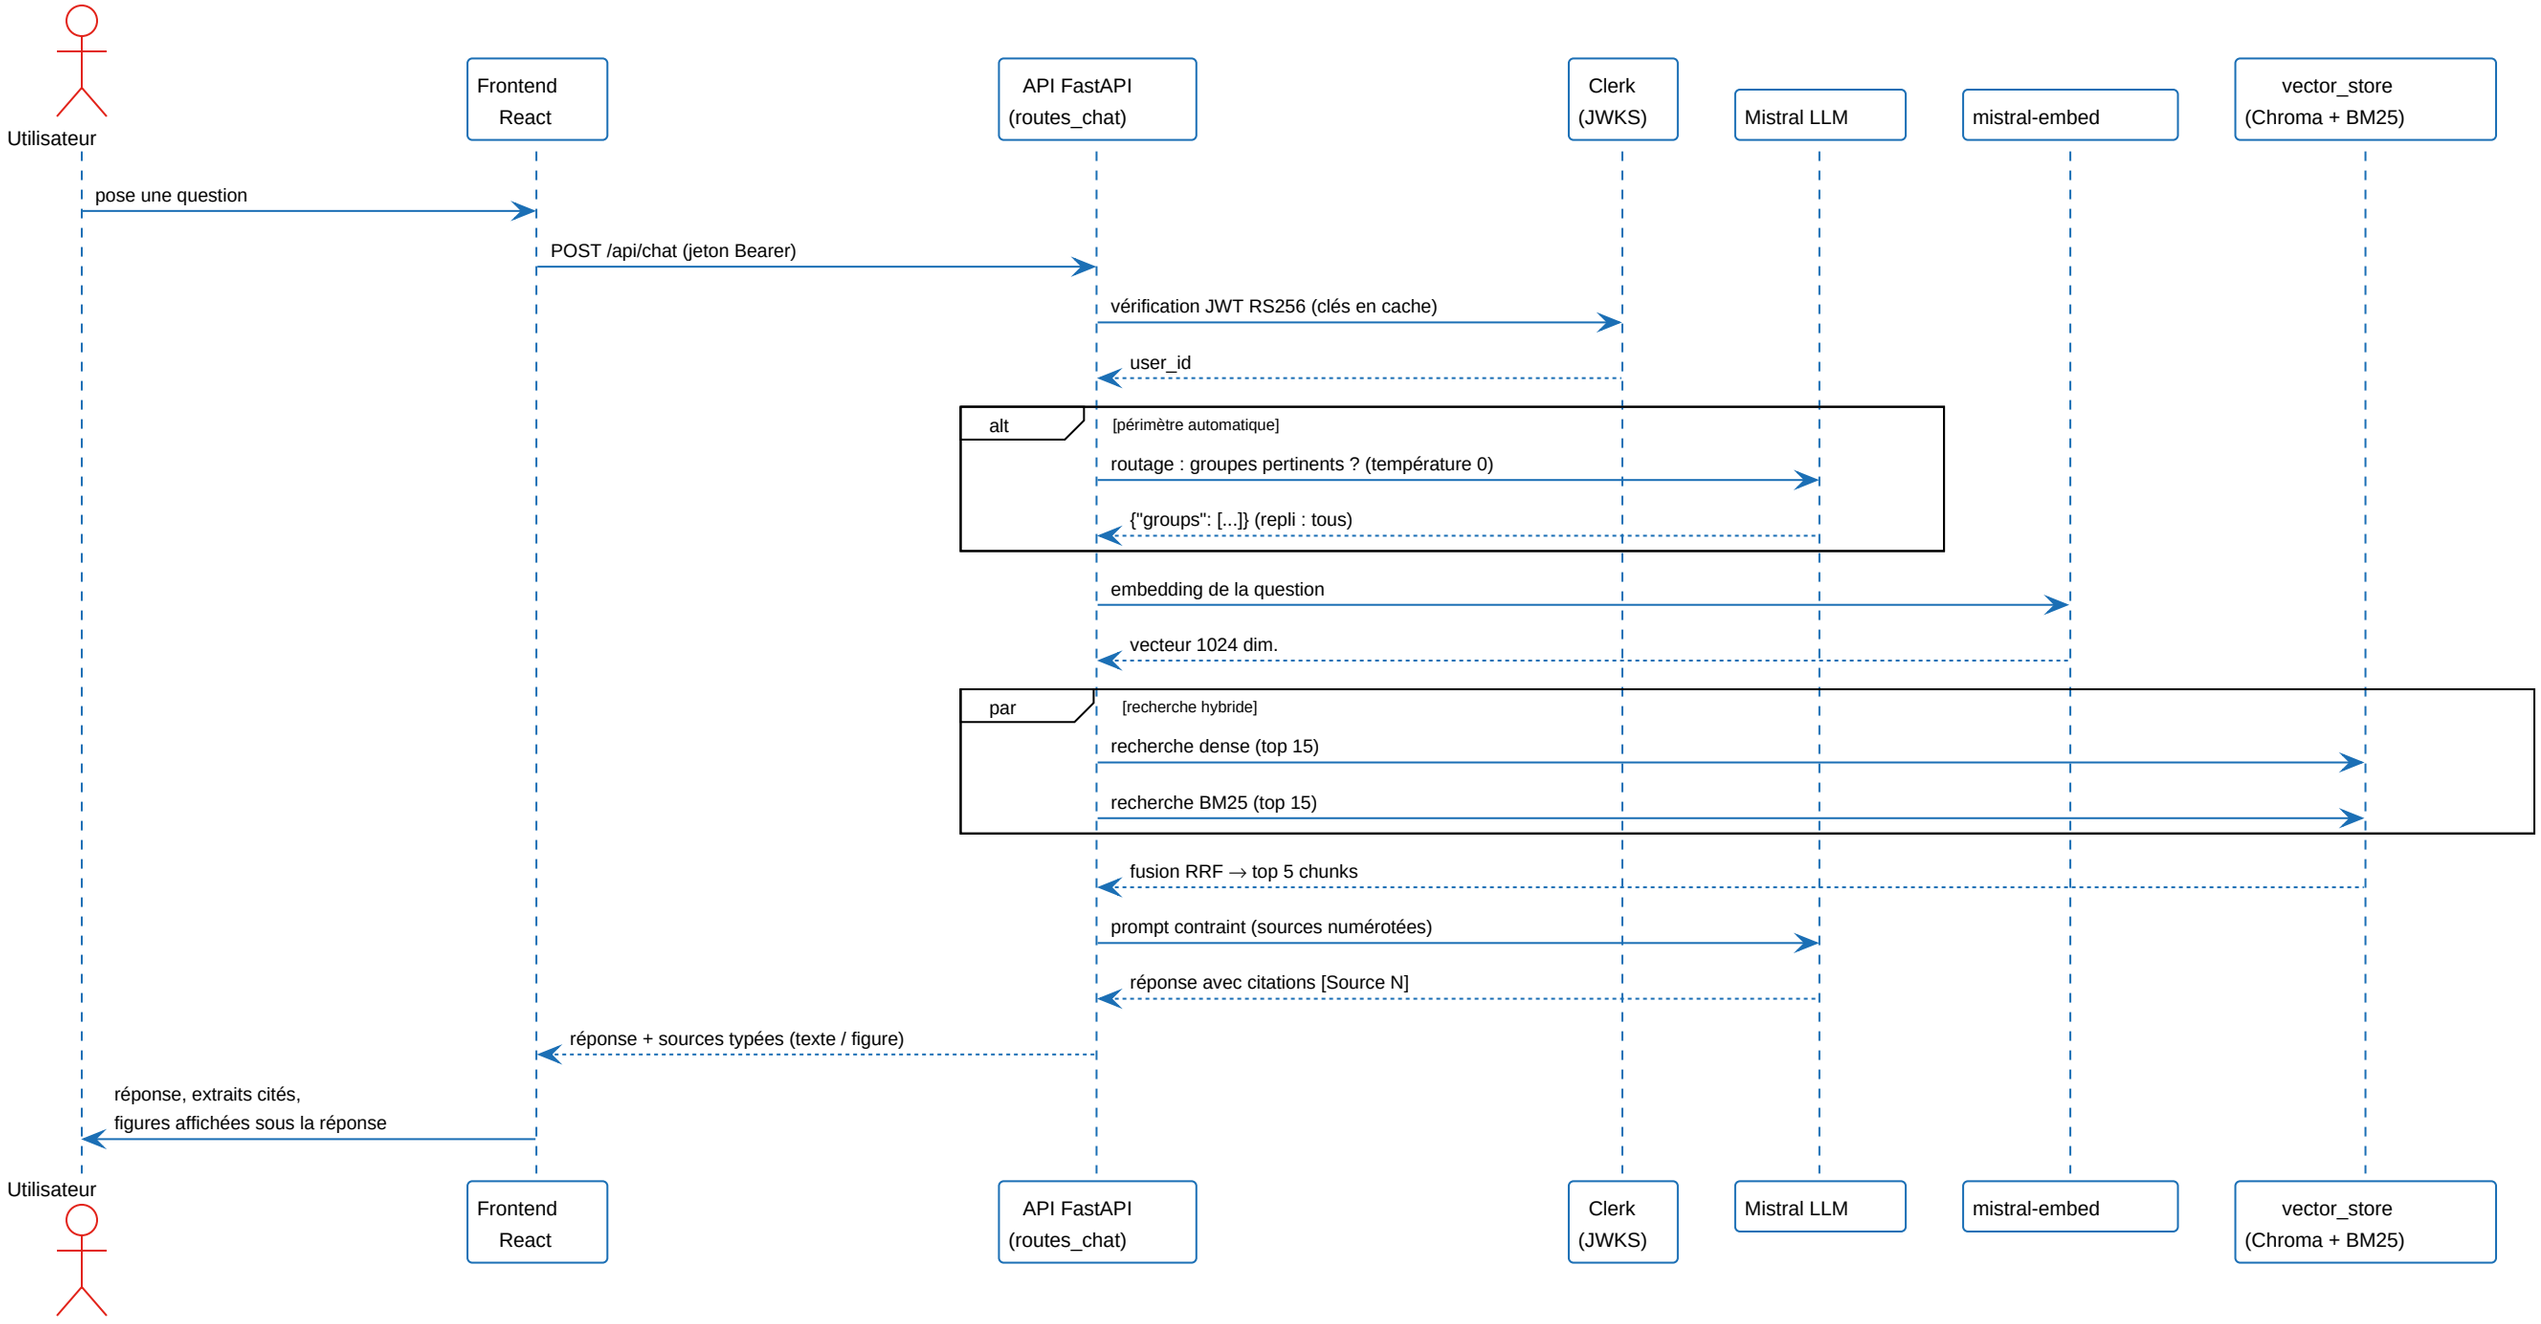
Utilisateur
Frontend
React
API FastAPI
(routes_chat)
Clerk
(JWKS)
Mistral LLM
mistral-embed
vector_store
(Chroma + BM25)
pose une question
POST /api/chat (jeton Bearer)
vérification JWT RS256 (clés en cache)
user_id
alt
[périmètre automatique]
routage : groupes pertinents ? (température 0)
{"groups": [...]} (repli : tous)
embedding de la question
vecteur 1024 dim.
par
[recherche hybride]
recherche dense (top 15)
recherche BM25 (top 15)
fusion RRF → top 5 chunks
prompt contraint (sources numérotées)
réponse avec citations [Source N]
réponse + sources typées (texte / figure)
réponse, extraits cités,
figures affichées sous la réponse
Utilisateur
Frontend
React
API FastAPI
(routes_chat)
Clerk
(JWKS)
Mistral LLM
mistral-embed
vector_store
(Chroma + BM25)