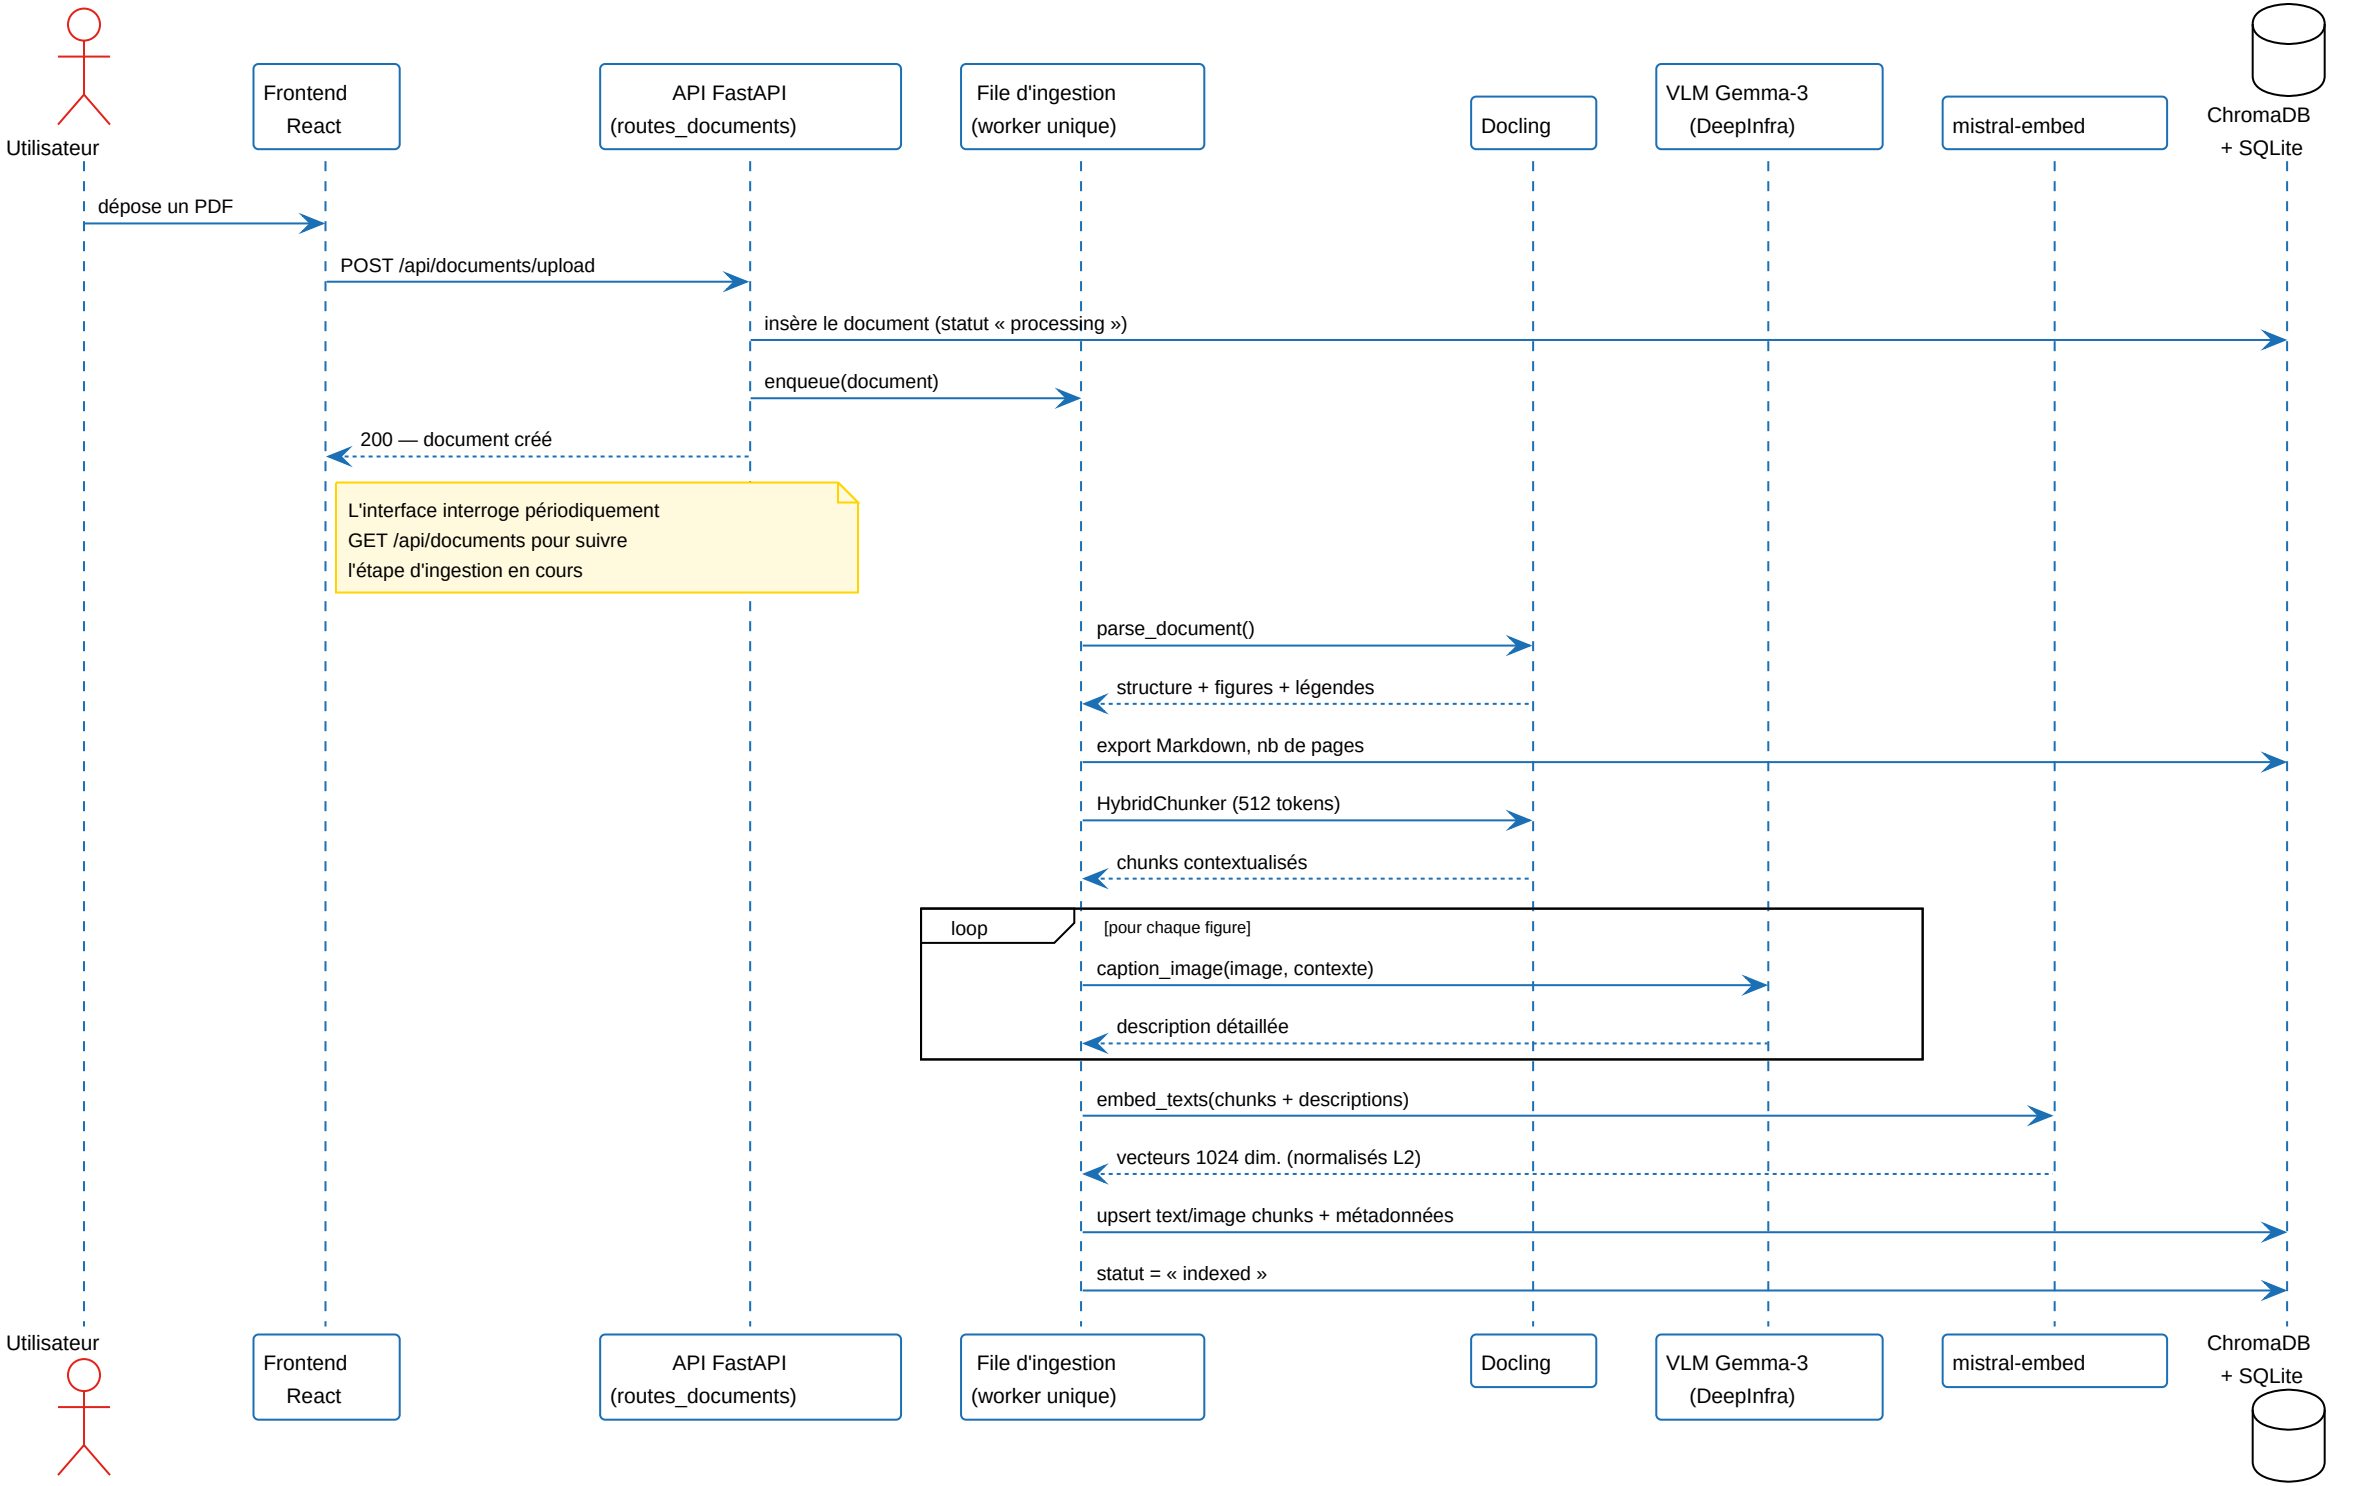
Utilisateur
Frontend
React
API FastAPI
(routes_documents)
File d'ingestion
(worker unique)
Docling
VLM Gemma-3
(DeepInfra)
mistral-embed
ChromaDB
+ SQLite
dépose un PDF
POST /api/documents/upload
insère le document (statut « processing »)
enqueue(document)
200 — document créé
L'interface interroge périodiquement
GET /api/documents pour suivre
l'étape d'ingestion en cours
parse_document()
structure + figures + légendes
export Markdown, nb de pages
HybridChunker (512 tokens)
chunks contextualisés
loop
[pour chaque figure]
caption_image(image, contexte)
description détaillée
embed_texts(chunks + descriptions)
vecteurs 1024 dim. (normalisés L2)
upsert text/image chunks + métadonnées
statut = « indexed »
Utilisateur
Frontend
React
API FastAPI
(routes_documents)
File d'ingestion
(worker unique)
Docling
VLM Gemma-3
(DeepInfra)
mistral-embed
ChromaDB
+ SQLite